

DTWNet: a Dynamic Time Warping Network

한양대학교 산업공학과 IDSL 석사과정 고경준

Contents

- 1. Introduction
- 2. Related Work
- 3. Proposed DTW Layer and its Backpropogation
- 4. DTW Loss and Convergence
- 5. Streaming DTW Learning
- 6. Experiments and Application

Introduction

- 다양한 Similarity or distance metric이 존재하지만 sequence data analysis domain에서는 Doppler effect를 반영하지 못하여 부적합한 경우가 대부분임.
- (Doppler effect : shifting and scaling in the time axis)
- Dynamic Time Warping(DTW)는 signal warping의 invariance를 지님.
- DTW는 distance measure 이외에 predefined patterns을 찾아내는 feature extracting tool으로 사용되기도 함.

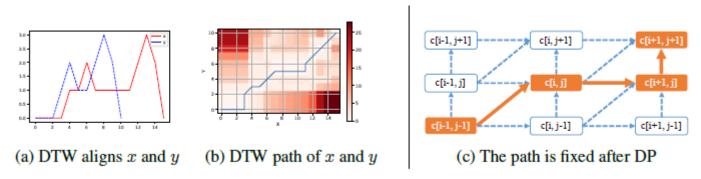



Figure 1: Illustration of DTW Computation, Dynamic Programming and Warping Path

Dynamic Programming process


Warping path



$$C_{i,j} = ||x_i - y_j|| + \min\{C_{i-1,j}, C_{i,j-1}, C_{i-1,j-1}\}$$

$$C_{3,2} = ||5 - 5|| + \min\{1, 7, 3\}$$
(1)

Dynamic Programming process



- Time axis에 상관없이 비슷한 형태의 데이터의 거리를 작게 측정할 수 있음.
- Length가 다른 데이터의 비교도 가능.

Key Contributions

- Neural network에 DTW kernels를 적용.
- Warping path를 기반으로 stochastic backpropagation method를 제안.
- 최초로 DTW loss function을 이론적으로 분석.
- Missing local features를 해결하기 위해 differentiable streaming DTW learning 제안.
- Data decomposition에 application.

2. Related Work

Introduction of Dynamic Time Warping

- Predefined patterns을 찾아내는 방식으로 feature extraction 한다.
- DP process에서 O(nl)의 time complexity 발생.
- 이미지 데이터에 관한 거리 계산이 가능한 Multi-variate DTW도 존재.

SPRING Algorithm, the Streaming Version of DTW

- Input sequence와 predefined patterns를 end-to-end로 학습하는 것이 아니라, 하나의 input에 같은 pattern이 반복되는 경우에 적용하기 위해 streaming version이 제시됨.
- 모든 subsequence를 비교할 경우 $O(n^2l)$ 이지만 SPRING 방식은 O(nl)

DTW as a Loss Function

- Min operation이 not continuous하므로 soft-min DTW가 적용됨.
- Soft-min idea가 사용된 사례에서 loss function을 DTW로 사용했을 때, Euclidean distance 보다 좋은 성능을 보인 사례가 존재.

3. Proposed DTW Layer and its Backpropogation

DTW Layer and Backpropagation

- Deep neural network에 DTW layer를 사용
- DTW layer는 feature를 추출하는 여러 개의 DTW kernels로 구성됨.
- DTW layer 이후에 linear layer를 추가하여 classification/regression 결과를 얻음.

Algorithm 1 DTWNet training for a classification task. Network parameters are: number of DTW kernels N_{kernel} ; kernels $x_i \in \mathcal{R}^l$; linear layers with weights w.

INPUT: Dataset $Y = \{(y_i, z_i) | y_i \in \mathcal{R}^n, z_i \in \mathcal{Z} = [1, N_{\text{class}}]\}$. The DTWNet dataflow can be denoted as $\mathcal{G}_{x,w} : \mathcal{R}^n \to \mathcal{Z}$.

OUTPUT: The trained DTWNet $\mathcal{G}_{x,w}$


- 1: Init w; For i=1 to N_{kernel} : randomly init x_i ; Set total # of iteration be T, stopping condition ϵ
- 2: **for** t = 0 to T **do**
- 3: Sample a mini-batch $(y, z) \in Y$. Compute DTWNet output: $\hat{z} \leftarrow \mathcal{G}_{x,w}(y)$
- 4: Record warping path \mathcal{P} and obtain determined form $f_t(x,y)$, as in Equation 2
- 5: Let $\mathcal{L}_t \leftarrow \mathcal{L}_{CrossEntropy}(\hat{z}, z)$. Compute $\nabla_w \mathcal{L}_t$ through regular BP.
- 6: For i=1 to N_{kernel} : compute $\nabla_{x_i} \mathcal{L}_t \leftarrow \nabla_{x_i} f_t(x_i, y) \frac{\partial \mathcal{L}_t}{\partial f_t}$ based on \mathcal{P} , as in Equation 3
- 7: SGD Update: let $w \leftarrow w \alpha \nabla_w \mathcal{L}_t$ and for i = 1 to N_{kernel} do $x_i \leftarrow x_i \beta \nabla_{x_i} \mathcal{L}_t$
- 8: If $\Delta \mathcal{L} = |\mathcal{L}_t \mathcal{L}_{t-1}| < \epsilon$: return $\mathcal{G}_{x,w}$

$$dtw^{2}(x,y) = f_{t}(x,y) = ||y_{0} - x_{0}||_{2}^{2} + ||y_{1} - x_{0}||_{2}^{2} + ||y_{2} - x_{1}||_{2}^{2} + \dots$$
(2)

$$\nabla_x \text{dtw}^2(x, y) = \nabla_x f_t(x, y) = [2(y_0 + y_1 - 2x_0), 2(y_2 - x_1), \dots]^T$$
(3)

3. Proposed DTW Layer and its Backpropogation


DTW Network



3. Proposed DTW Layer and its Backpropogation

Gradient Calculation and Backpropogation

- 편미분 과정은 Warping path에 관해서만 계산되기 때문에, warping path의 최대 길이인 O(n+l)time만큼 걸림.
- DP part는 not parallelizable하지만, 각 커널끼리는 parallelizable한 계산이 가능.



```
가장 긴 path : 6+12 = n+l
가장 짧은 path : 6 +(12-6)
= min(n,l) + (max(n,l)-min(n,l))
= max(n,l)
```

Definitions and conditions

• One Input sequence $y \in R^n$ 에 대해 $\min_x dtw^2(x,y)$ 인 kernel $x \in R^l$ 를 찾는 문제. $(l \le n)$

Definition 1. Since DP provides a deterministic warping path for arbitrary x, we define the space of all the functions of x representing all possible warping paths as

$$\mathcal{F}_y = \{ f_y(x) | f_y(x) = \sum_{i,j} I_{ij} | |(x_i - y_j)||_2^2 \}$$

s.t. $i \in [0, l-1]; j \in [0, n-1]; I_{ij} \in \{0, 1\}; n \leq |I| \leq n+l;$ i, j satisfy temporal order constraints.

(I는 warping path에서는 1, 나머지는 0인 I행 n열 matrix. x_i 와 y_i 가 mapping될 경우 x_{i+1} 은 y_{i-1} 와 mapping 될 수 없음.)

- DTW distance function을 $d = H_y(x)$ 라고 정의. ($d \in R$)
- 따라서 임의의 x인 \widehat{x} 에 대해 $H_y(x)|_{x=\widehat{x}}=f_y^{(u)}(x)|_{x=\widehat{x}}\;,\;\;f_y^{(u)}\in\mathcal{F}_y.$
- 이 때, $\nabla_x f_y^{(u)}(x)|_{x=\hat{x}} = \nabla_x H_y(x)|_{x=\hat{x}}$. 을 확인.

Definitions and conditions


■ $H_{\nu}(x)$ 는 x의 공간에서 not smooth하기 때문에 (4)를 만족하는 x가 존재.

$$H_y(x) = \begin{cases} f_y^{(u)}(x)|_{x=x_+} & u \neq v; \ f_y^{(u)}, f_y^{(v)} \in \mathcal{F}_y \\ f_y^{(v)}(x)|_{x=x_-} \end{cases}$$
 (4)

■ Warping path의 계산은 3방향에서 정해지므로 Lemma 1이 성립.

Lemma 1. Warping paths number $|\mathcal{F}_y| < 3^{n+l}$, where (n+l) is the largest possible path length.

• 따라서 $H_{\nu}(x)$ 는 piece-wise quadratic/linear function (2-norm/absolute DTW loss)



HANYANG UNIVERSITY

Escaping Local Minima

$$\mathcal{U} = \{i, j | i \neq k, j \notin [p, p+q]\}, I_{ij} \in \{0, 1\}$$

- $f_y^{(u)}$ 인 지역 u에서 $f_y^{(v)}$ 인 지역 v로 넘어가는 과정에 대한 내용.
- DP 이후 $y_{p:p+q}$ 가 x_k 에 align되었다면, $f_{y}^{(u)}$ 를 (5)처럼 x_k 에 관해 작성 가능.

$$f_y^{(u)} = \sum_{j=p}^{p+q} (y_j - x_k)^2 + \sum_{i,j \in \mathcal{U}} I_{ij} (x_i - y_j)^2 \quad \text{and} \quad \nabla_{x_k} f_y^{(u)} = \sum_{j=p}^{p+q} 2(x_k - y_j)$$
 (5)

• Local minimum은 $\nabla_{x_k} f_y^{(u)} = 0$ 를 만족하는 $x_k^{(u)*} = \frac{1}{q+1} \sum_{j=p}^{p+q} y_j$.

$$f_y^{(v)} = \sum_{j=p}^{p+q+1} (y_j - x_k)^2 + \sum_{i,j \in \mathcal{V}} I_{ij} (x_i - y_j)^2$$
 (6)


ullet (6)을 만족하는 local minimum을 $x_k^{(v)*}$, $\sum_{j=p}^{p+q-1} y_j$ 에 관한 local minimum을 $x_k^{(w)*}$ 라고 하면

$$x_k^{(u)*} = \frac{\sum_{j=p}^{p+q} y_j}{q+1} , \quad x_k^{(v)*} = \frac{\sum_{j=p}^{p+q+1} y_j}{q+2} , \quad x_k^{(w)*} = \frac{\sum_{j=p}^{p+q-1} y_j}{q}$$
 (7)

Escaping Local Minima

■ 지역 w, u, v가 좌에서 우로 위치한다고 가정하면 Figure 2 (c), (d)처럼 표현됨.

i.e., $x_k^1 < x_k^2 < x_k^3$, for $x_k^1 \in w, x_k^2 \in u, x_k^3 \in v$.



 $x_k^{(w)*}$ $x_k^{(u)*}$ $x_k^{(v)*}$

Figure 2

(c) Analysis case 1

(d) Analysis case 2

Case 1.

- Figure2c처럼 $x_k^{(v)*}$ 가 region v의 왼쪽에 있는 경우, 학습이 진행되면서
- region u로 돌아오기 때문에 u에서 v로 jump할 수 없음

Escaping Local Minima

지역 w, u, v가 좌에서 우로 위치한다고 가정하면 Figure 2 (c), (d)처럼 표현됨.

i.e., $x_k^1 < x_k^2 < x_k^3$, for $x_k^1 \in w, x_k^2 \in u, x_k^3 \in v$.




Figure 2

(c) Analysis case 1 (d) Analysis case 2


Case 2.

- Figure 2 d처럼 u와 v 모두 bowl 형태인 경우, 두 지역의 경계는 $x_k^{(v)*}$ 와 $x_k^{(u)*}$ 의 사이에 위치.
- 시작점 $x_k = \widetilde{x} \in u$ 는 $x_k^{(u)*}$ 보다 왼쪽에 위치해야 하고 (빨간 화살표 위치)
- $x_k^{(v)*} \tilde{x}$ 만큼 이상을 움직여야 함. (두 지역의 경계가 $x_k^{(v)*}$ 와 매우 인접할 수 있으므로)

Escaping Local Minima

■ 지역 w, u, v가 좌에서 우로 위치한다고 가정하면 Figure 2 (c), (d)처럼 표현됨.

i.e.,
$$x_k^1 < x_k^2 < x_k^3$$
, for $x_k^1 \in w, x_k^2 \in u, x_k^3 \in v$.






Figure 2

(c) Analysis case 1

(d) Analysis case 2


Case 3.

- v가 bowl 형태가 아니면서 $x_k^{(v)*}$ 가 region v의 오른쪽에 있는 경우,
- Case 2와 같은 조건 (시작 위치와 이동 거리)에서
- Figure 2c처럼 region v의 right neighbor (v+)와 합쳐진 combined region [v, v+]에 도달

Escaping Local Minima

■ 지역 w, u, v가 좌에서 우로 위치한다고 가정하면 Figure 2 (c), (d)처럼 표현됨.

i.e., $x_k^1 < x_k^2 < x_k^3$, for $x_k^1 \in w, x_k^2 \in u, x_k^3 \in v$.



 $x_k^{(w)*}$ $x_k^{(u)*}$ $x_k^{(y)*}$

Figure 2

(c) Analysis case 1

(d) Analysis case 2

■ 2,3번 case에서 u에서 v로 jump하려면 Step size가 I/2n보다 커야함.

Theorem 1. Assume that the starting point at coordinate k, i.e. $x_k = \tilde{x}$, is in some region u where $f_y^{(u)}$ is defined in Equation 5. Let x and y have lengths n and l, respectively, and assume that l < n. To ensure escaping from u to its immediate right-side neighbor region, the expected step size $\mathbb{E}[\eta]$ needs to satisfy: $\mathbb{E}[\eta] > \frac{l}{2n}$.

Proof of theorem 1

A Proof of Theorem 1

Proof. As discussed above, we have two cases as follows.

Case 1: First we consider the case that w, u, v are from left to right, with their stationary points $x_k^{(w)*} < x_k^{(u)*} < x_k^{(v)*}$. A standard gradient descent update is $\tilde{x} \leftarrow \tilde{x} - \eta \nabla_{x_k} f_y^{(u)}|_{x_k = \tilde{x}}$. To ensure one step update could make \tilde{x} jump from u to v, we obtain:

$$\tilde{x} - \eta \nabla_{x_k} f_y^{(u)}|_{x_k = \tilde{x}} \ge x_k^{(v)*}$$

$$\Rightarrow \tilde{x} - \eta \sum_{j=p}^{p+q} 2(\tilde{x} - y_j) \ge x_k^{(v)*} \text{ (use Equation 5)}$$

$$\Rightarrow (1 - 2\eta(q+1))\tilde{x} + 2\eta(q+1) \frac{1}{q+1} \sum_{j=p}^{p+q} y_j \ge x_k^{(v)*}$$

$$\Rightarrow (1 - 2\eta(q+1))\tilde{x} \ge x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*} \text{ (use Equation 7)}$$

Proof of theorem 1

Now we have two possibilities:

Possibility (a): $1 - 2\eta(q+1) > 0$:

Inequality 11
$$\Rightarrow \tilde{x} \ge \frac{x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*}}{1 - 2\eta(q+1)}$$

To guarantee the gradient direction points to neighbor v, the starting point \tilde{x} has to be to the left of $x_k^{(u)*}$, thus:

$$\frac{x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*}}{1 - 2\eta(q+1)} \le \tilde{x} < x_k^{(u)*}$$

$$\Rightarrow x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*} < (1 - 2\eta(q+1))x_k^{(u)*}$$

$$\Rightarrow x_k^{(v)*} < x_k^{(u)*}$$
(12)

This is contradictory to the assumption that $x_k^{(w)*} < x_k^{(u)*} < x_k^{(v)*}$, and thus is not valid.

Proof of theorem 1

Possibility (b): $1 - 2\eta(q+1) < 0$:

Inequality
$$11 \Rightarrow \tilde{x} \leq \frac{x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*}}{1 - 2\eta(q+1)}$$

Due to the fact that \tilde{x} is inside region u, which must be somewhere to the right of $x_k^{(w)*}$ (with the assumption that w has a bowl-shape), we have:

$$\frac{x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*}}{1 - 2\eta(q+1)} \ge \tilde{x} > x_k^{(w)*}$$

$$\Rightarrow x_k^{(v)*} - 2\eta(q+1)x_k^{(u)*} < (1 - 2\eta(q+1))x_k^{(w)*}$$

$$\Rightarrow x_k^{(v)*} - x_k^{(w)*} < 2\eta(q+1)(x_k^{(u)*} - x_k^{(w)*})$$

$$\Rightarrow \eta > \frac{1}{2(q+1)} \left(\frac{x_k^{(v)*} - x_k^{(w)*}}{x_k^{(u)*} - x_k^{(w)*}}\right)$$
(13)

Recall that q is an integer and $q \ge 0$, thus

$$1 - 2\eta(q+1) < 0 \Rightarrow \eta > \frac{1}{2(q+1)} \tag{14}$$

Also notice that

$$x_k^{(w)*} < x_k^{(u)*} < x_k^{(v)*} \Rightarrow \frac{x_k^{(v)*} - x_k^{(w)*}}{x_k^{(u)*} - x_k^{(w)*}} > 1$$
 (15)

IVERSIT

Proof of theorem 1

Case 2: here w, u, v are from right to left, and $x_k^{(w)*} > x_k^{(u)*} > x_k^{(v)*}$. This is very similar to Case 1, so we omit the details and provide the final result as

$$\eta > \frac{1}{2(q+1)} \left(\frac{x_k^{(w)*} - x_k^{(v)*}}{x_k^{(u)*} - x_k^{(v)*}} \right) \quad \text{and} \quad \frac{x_k^{(w)*} - x_k^{(v)*}}{x_k^{(u)*} - x_k^{(v)*}} > 1 \tag{16}$$


We will arrive at the same result: $\eta > \frac{1}{2(q+1)}$.

Note that the length of the pattern x is l and the length of input y is n. As a result, the expected number of elements in y aligned to a single x_i , $i \in [0, l-1]$ should be n/l, i.e. $\mathbb{E}[q] = n/l - 1$. Taking expectation on both sides of the above inequality, we obtain $\mathbb{E}[\eta] > \frac{1}{2(n/l-1+1)} = \frac{l}{2n}$. \square

5. Streaming DTW Learning

Spring algorithm

- Input data에 pattern이 여러 번 반복되는 경우엔 kernel이 전체 input에 대한 pattern을 학 습하려고 하기 때문에 문제가 발생.
- Window를 정해서 subsequence와 kernel간의 DTW를 줄여주는 방식.



$$x^* = \arg\min_{i,\Delta,x} dtw^2(x, y_{i:i+\Delta})$$

- Network를 통해 DTW distance를 계산하여 지금까지 중 가장 작은 경우(best i, △)를 기억.
- 다음 input이 들어오면 i, Δ 를 다르게 설정하여 학습한 뒤, output distance가 minimum distance보다 작으면 해당 i, Δ 를 (best i, Δ)로 기억 후 kernel 학습


5. Streaming DTW Learning

Regularizer in Streaming DTW

- SPRING은 input sequence 중 반복되는 pattern을 찾아내는 알고리즘이기 때문에 일반적으로 나타날 수 있는 오르거나 내리는 형태도 pattern으로 인식하게 됨.
- 또는 pattern의 오르거나 내리는 일부분만 학습하게 됨.

$$\min_{i,\Delta,x} (1 - \alpha) dtw^{2}(x, y_{i:i+\Delta}) + \alpha ||x_{0} - x_{l}||$$
(9)

Kernel의 처음과 끝의 거리를 줄여주어 일부분만 학습하는 오류를 방지.



■ 또한 pattern에 대한 사전 정보가 있는 경우, 그와 관련된 regularizer를 추가할 수 있음.

6. Experiments and Applications

Comparison with Convolution Kernel

- 처음 설명한 End-to-end 방식을 Full DTW, streaming 방식을 SPRING DTW라고 표현.
- 인공적인 timeseries input data를 생성하여 성능을 비교.
- 각 time series는 Pattern 1(half square), Pattern 2(upper triangle) 중 1개가 2번 발생.
- 발생하는 Pattern의 위치와 길이는 random하고, Gaussian noise가 추가된 형태.




Figure 4: Performance comparison on synthetic data sequences (400 iterations)

- Training set : 각 pattern 별 50개씩 총 100개
- Test set : 각 pattern 별 50개씩 총 100개
- Full DTW, SPRING DTW, convolution kernel (length 10)를 각각 학습시킴.
- Set α = 0.1 in SPRING DTW, 3 linear layers

6. Experiments and Applications

Evaluation of Gradient Calculation

- Proposed BP schem의 accurac를 비교하기 위한 실험.
- 이를 위해 여러가지 방식으로 barycenter를 계산하고 최종 loss를 비교해 봄.

$$\mathcal{L}_{ ext{dtw}} = rac{1}{N_{ ext{class}}} \sum_{i=0}^{N_{ ext{class}}} rac{1}{N_i} \sum_{j=0}^{N_i} ext{dtw}(s_{i,j}, b_i)$$

(i class를 가지는 j번째 input sequence와 barycenter간의 dtw N_{class} 는 category 개수, N_i 는 i class인 sequence의 개수)




Table 1: Barycenter Experiment Summary

(10)

	Training Set				Testing Set			
Alg	SoftDTW	SSG	DBA	Ours	SoftDTW	SSG	DBA	Ours
Win	4	23	21	37	11	21	22	31
Avg-rank	3.39	2.14	2.27	2.2	3.12	2.31	2.36	2.21
Avg-loss	27.75	26.19	26.42	24.79	33.08	33.84	33.62	31.99

6. Experiments and Applications

Application of DTW Decomposition

- DTW layer를 여러 겹 쌓아서 decomposition effect를 얻을 수 있음.
- 앞부분의 DTW layer residual을 다음 DTW layer에 forwarding하는 idea.




Figure 5: Illustration of DTW Decomposition

- 5개의 DTW layer에 1개의 kernel만 배정하여 학습하면, 일반적으로
- first layer에서는 전체적인 pattern (low-frequency)을,
- last layer에서는 high-frequency pattern을 학습하는 모습을 보임.

감사합니다.